Insertion sort

Clase 02

IIC 2133 - Sección 3

Prof. Eduardo Bustos

Sumario

Introducción

Insertion Sort

Inversiones

Cierre

Primer Acto: Ordenación y fundamentos Ordenación y análisis de algoritmos

Correctitud de algoritmos

En este curso nos centraremos en dos propiedades para decir que un algoritmo es correcto:

- Termina en una cantidad finita de pasos
- Cumple su propósito

En un problema de ordenación, un algoritmo será correcto si ordena los datos en una cantidad finita de pasos

El algoritmo SelectionSort

input: Secuencia de datos A

output: Nueva secuencia de datos B, ordenada

SelectionSort (A):

- 1 Definir secuencia B, inicialmente vacía
- Buscar el menor dato x en A
- Sacar x de A e insertarlo al final de B
- 4 Si quedan valores en *A*, volver a la línea 2 **return** *B*

Un paréntesis sobre la escritura de datos

No olvidemos el espíritu del curso: estructuras de datos

iQué tan costosa es la inserción del dato al final de B en SelectionSort?

En el contexto de SelectionSort nos interesa específicamente la inserción del último elemento

- En una lista ligada, si se cuenta con un puntero adicional al último elemento, la inserción toma $\Theta(1)$
- En un arreglo
 - si no se supera el espacio reservado para este, toma $\Theta(1)$
 - si se agotó el espacio, hay que reubicar todo el arreglo: $\Theta(n)$

Un paréntesis sobre la escritura de datos

Con esto, las operaciones que conocemos tienen las siguientes complejidades

| Operación | Arreglo | Lista ligada |
|-------------------|---|----------------------------------|
| Acceso por índice | Θ(1) | $\Theta(n)$ |
| Inserción (final) | $\Theta(1)$ sin reubicar $\Theta(n)$ reubicando | $\Theta(1)$ con puntero al final |

No perdamos de vista la pregunta de qué estructura es la **más adecuada** en cada escenario

Cabe notar que para el caso de los arreglos, en SelectionSort sabemos exactamente cuánto espacio necesitamos reservar

Más aún, veremos una forma de usar la menor cantidad de memoria posible con arreglos

Complejidad de memoria en SelectionSort

 Cabe notar que SelectionSort se puede hacer en un solo arreglo, ya que en todo minuto

$$|A| + |B| = n$$

- Como reciclamos el espacio dentro del mismo arreglo para llevar la nueva secuencia B, no es necesario reubicar el arreglo y toda inserción al final de B toma tiempo $\Theta(1)$
- Esta estrategia no necesita memoria adicional... o más precisamente, necesita $\mathcal{O}(1)$ de memoria adicional
- Los algoritmos que tienen esta propiedad se conocen como algoritmos in place

Continuamos ordenando el curso

- El sistema sigue malo, pero al menos ya ordenamos la lista de asistentes
- Sin embargo, ahora la Universidad nos pide cambiar 5 estudiantes de la sección 1 a la sección 2
- Tenemos que actualizar las listas de ambos cursos manteniendo el orden
- ¿Hay alguna forma de actualizar sin tener que ordenar todo de nuevo?

Una posible solución

- En lugar de ordenar desde cero, podemos insertar elementos respetando el orden
- Insertar pocos elementos ordenadamente debiera ser (relativamente) barato
- ¿Cómo podemos usar este hecho para ordenar?
- ¿Cómo se deben insertar los elementos para asegurar el orden? ¿Al final?

El algoritmo InsertionSort

input: Secuencia de datos A

output: Nueva secuencia de datos B, ordenada

InsertionSort (A):

- 1 Definir secuencia B, inicialmente vacía
- 2 Tomar el primer dato x de A
- Sacar x de A
- Insertar x en B de manera que B quede ordenada
- 5 Si quedan datos en *A*, volver a la línea 2 return *B*

¿En qué se diferencia InsertionSort de SelectionSort?

Objetivos de la clase

- ☐ Distinguir diferencias de InsertionSort y SelectionSort
- Demostrar correctitud de InsertionSort
- □ Comprender el efecto de la inserción general en las EDD básicas
- Comprender concepto de inversión y su rol en la ordenación
- ☐ Comprender casos (mejor, peor y promedio) en análisis en complejidad
- ☐ Determinar complejidad por caso para InsertionSort

Sumario

Introducción

Insertion Sort

Inversiones

Cierre

El algoritmo InsertionSort

input: Secuencia de datos A

output: Nueva secuencia de datos B, ordenada

InsertionSort (A):

- 1 Definir secuencia B, inicialmente vacía
- Tomar el primer dato x de A
- 3 Sacar x de A
- Insertar x en B de manera que B quede ordenada
- 5 Si quedan datos en *A*, volver a la línea 2 return *B*

La idea empleada por los algoritmos es diferente

- SelectionSort: elegir ordenadamente
- InsertionSort: insertar ordenadamente

Este algoritmo es correcto y demostraremos su correctitud de manera similar al caso de SelectionSort

input: Secuencia de datos A

output: Nueva secuencia de datos B, ordenada

InsertionSort (A):

- 1 Definir secuencia B, inicialmente vacía
- Tomar el primer dato x de A
- Sacar x de A
- Insertar x en B de manera que B quede ordenada
- 5 Si quedan datos en *A*, volver a la línea 2 return *B*

¿En qué se diferencian ambas demostraciones?

Demostración (finitud)

Sea n la cantidad (finita) de valores en la secuencia original A.

En cada iteración del algoritmo se borra un valor de A (línea 3).

Luego se inserta dicho valor en B (línea 4), para lo cual se requiere como máximo recorrer todo B. Como en todo minuto B tiene largo finito, la inserción toma una cantidad finita de pasos.

Luego de n iteraciones, todos los valores en A fueron borrados. La condición de término (línea 5) garantiza que el algoritmo termina.

Por lo tanto, el algoritmo termina en una cantidad finita de pasos.

Demostración (ordenación)

Consideremos la propiedad

P(n) := Luego de la*n*-ésima iteración,*B*se encuentra ordenada

1. Caso base.P(1) corresponde al estado de la secuencia B luego de insertar el primer elemento. Dado que B solo tiene un elemento, está ordenada.

Demostración (ordenación)

- P(n) := Luego de la n -ésima iteración, B se encuentra ordenada
- 2. H.I. Suponemos que luego de la *n*-ésima iteración, *B* está ordenada.
 - **P.D.** Luego de la iteración (n+1)-ésima iteración, B sigue ordenada.

En la iteración n+1 extraemos el primer elemento de A, a saber a'. Si el estado de B es

$$a_1 \leq \cdots \leq a_i \leq a_{i+1} \leq \cdots \leq a_n$$

y a' cumple $a_i \le a' \le a_{i+1}$, lo insertamos de forma que B satisface

$$a_1 \leq \cdots \leq a_i \leq a' \leq a_{i+1} \leq \cdots \leq a_n$$

Es decir, luego de la iteración n + 1, B está ordenada.

Inserción de datos

InsertionSort y SelectionSort no solo se diferencian en su estrategia.

También difieren en cómo realizan la inserción del dato en cada iteración

- SelectionSort inserta siempre al final de la nueva EDD
- InsertionSort inserta de forma que la nueva EDD quede ordenada, no necesariamente haciéndolo al final de esta

Nuestro análisis de complejidad de la inserción es insuficiente: interesa poder insertar en **cualquier posición**

¿Cómo cambia nuestro análisis de complejidad de la inserción?


Inserción de datos

Toda inserción de un dato en una estructura involucra dos pasos

- 1. Búsqueda de la posición en que se debe insertar el dato
- 2. Inserción propiamente tal, quizás incluyendo mover otros datos

¿Cuál es la complejidad de estos pasos usando arreglos? ¿Y listas ligadas?

Inserción en arreglo ordenado



Inserción en arreglo ordenado

Para un arreglo de largo n

La búsqueda de la posición adecuada requiere un algoritmo de búsqueda

■ Si usamos búsqueda binaria, toma tiempo $\mathcal{O}(\log(n))$

Para insertar un elemento en una posición es posible que haya que desplazar elementos ya ordenados

- Si el elemento es mayor que todos, se agrega al final
- En caso contrario, hay que desplazar todos los mayores a él
- Esto toma tiempo $\mathcal{O}(n)$

La inserción en arreglos ordenados toma tiempo $\mathcal{O}(n)$

Inserción en lista (doblemente) ligada

Consideramos una lista ligada con n elementos ordenados

La búsqueda de la posición adecuada requiere revisar la lista completa

Esto toma tiempo $\mathcal{O}(n)$

Para insertar un elemento en una posición solo hay que reasignar punteros

- A lo más involucra 2 elementos previamente ordenados
- Esto toma tiempo $\mathcal{O}(1)$

La inserción en listas ligadas ordenadas toma tiempo $\mathcal{O}(n)$

Ya sabemos que la complejidad de la inserción es $\mathcal{O}(n)$ para EDDs básicas.

```
Ejercicio
¿Cuál es la complejidad de InsertionSort?
  input : Secuencia de datos A
  output: Nueva secuencia de datos B, ordenada
  InsertionSort (A):
     Definir secuencia B, inicialmente vacía
1
     Tomar el primer dato x de A
2
     Sacar x de A
3
     Insertar x en B de manera que B quede ordenada
     Si quedan datos en A, volver a la línea 2
5
     return B
```

Ejecución de InsertionSort

Para buscar la intuición, consideremos una versión in place del algoritmo

- Tal como con SelectionSort, |A| + |B| = n se mantiene luego de cada iteración, i.e. es un invariante
- Podemos usar un mismo arreglo para ambas secuencias

```
\begin{array}{ll} \textbf{input} & : \mathsf{Secuencia} \ A[0 \dots n-1], \ \mathsf{largo} \ n \geq 2 \\ \textbf{output:} \ \varnothing \\ & \mathsf{InsertionSort} \ (A,n) \text{:} \\ & \mathsf{for} \ i = 1 \dots n-1 : \\ & j = i \\ & \mathsf{while} \ (j > 0) \land (A[j] < A[j-1]) : \\ & \mathsf{Intercambiar} \ A[j] \ \mathsf{con} \ A[j-1] \\ & \mathsf{j} = \mathsf{j} - 1 \end{array}
```


Ejecución de InsertionSort

| $j-1 \rightarrow 0$ | 20 | |
|----------------------|----|--|
| $i, j \rightarrow 1$ | 82 | |
| 2 | 8 | |
| 3 | 29 | |
| 4 | 60 | |
| 5 | 32 | |
| 6 | 40 | |
| 7 | 70 | |
| 8 | 41 | |
| 9 | 15 | |

Iteración con i = 1: no hay intercambio entre A[1] y A[0]

Iteración con i = 2: hay dos intercambios $A[2] \leftrightarrow A[1]$ y $A[1] \leftrightarrow A[0]$

InsertionSort puede hacer $\mathcal{O}(n)$ intercambios por elemento



próximo dato a ser insertado ordenadamente: G

¿Qué tiempo toma si los datos vienen ordenados?

AEEGILMNOPRSTX

- A diferencia de SelectionSort que revisa toda la secuencia A para encontrar el menor elemento, InsertionSort siempre toma el primer elemento de A
- Si los datos vienen ordenados, SelectionSort no cambia su complejidad
- En InsertionSort la inserción se ve beneficiada: sirve recordar dónde termina la lista ordenada para saber dónde insertar
- Pareciera entonces que la complejidad de InsertionSort depende de qué tan ordenados están los datos

¿Cómo medir qué tan ordenados vienen los datos?

Sumario

Introducción

Insertion Sort

Inversiones

Cierre

Inversiones

Definición

Sea A un arreglo de n números distintos entre 0 y n-1, y sean $0 \le i, j \le n-1$ índices del arreglo. Si i < j y A[i] > A[j], entonces diremos que el par ordenado (i,j) es una inversión.

Usaremos el número de inversiones en un arreglo como una métrica de desorden

¿Esta idea sirve cuando hay repetidos? ¿Y cuando hay números fuera del rango $0 \dots n-1$?

Inversiones

Definición

Sea A un arreglo de n números y sean $0 \le i, j \le n-1$ índices del arreglo. Si i < j y A[i] > A[j], entonces diremos que el par ordenado (i,j) es una inversión.

Ejemplo

El arreglo

tiene 9 inversiones:

- **(**0,1), (0,4), (0,5)
- **(**2,3), (2,4), (2,5)
- **(**3,4), (3,5)
- **4**,5)

Inversiones e InsertionSort

Recordemos la versión in place del algoritmo

```
input : Secuencia A[0 \dots n-1], largo n \ge 2

output: \varnothing

InsertionSort (A, n):

1 for i = 1 \dots n-1:

2 j = i

3 while (j > 0) \wedge (A[j] < A[j-1]):

4 Intercambiar A[j] con A[j-1]

5 j = j-1
```

Consideremos un arreglo A de largo n con k inversiones

- ¿Cuántas inversiones se arreglan con un intercambio (línea 4)?
- ¿Cuánto tiempo toma InsertionSort en ordenar A?

Inversiones e InsertionSort

```
input : Secuencia A[0 \dots n-1], largo n \ge 2

output: \varnothing

InsertionSort (A, n):

1 for i = 1 \dots n-1:

2 j = i

3 while (j > 0) \land (A[j] < A[j-1]):

4 Intercambiar A[j] con A[j-1]

5 j = j-1
```

- Antes de cada intercambio, comparan los datos con índices j y j-1
- Los datos se intercambian solo si el par (j-1,j) es una inversión
- Por lo tanto, cada intercambio de datos adyacentes corrije exactamente una inversión
- Además, cada dato se compara al menos una vez

De acuerdo a lo anterior, la complejidad es

$$\mathcal{O}(n+k)$$

- n considera que cada dato se compara al menos una vez
- k es el número de inversiones

¿Qué valor tiene k en el mejor caso? ¿Y en el peor?

Mejor y peor caso de InsertionSort

En el mejor caso, el arreglo tiene k = 0 inversiones

■ El arreglo está ordenado y la complejidad en el mejor caso es $\mathcal{O}(n)$

Mejor y peor caso de InsertionSort

En el peor caso, el arreglo tiene el número máximo de inversiones

- El arreglo está ordenado decrecientemente
- Al comparar cada índice i con j > i, se cuenta una inversión

$$k = (n-1) + (n-2) + \dots + 1 = \sum_{i=1}^{n-1} i = \frac{n(n-1)}{2}$$

 De forma equivalente, el número de inversiones es el número de pares de índices

$$k = \binom{n}{2} = \frac{n!}{2!(n-2)!} = \frac{n(n-1)}{2}$$

■ La complejidad en el peor caso es $\mathcal{O}(n^2)$

¿ Qué hay del caso promedio?

Haremos el análisis de caso promedio abstrayendo el orden del arreglo

Para esto, consideramos un arreglo A que viene en cualquier orden

¿Cuál es el número promedio de inversiones en un arreglo con n datos?

Para dar una definición supondremos que \boldsymbol{A} no tiene elementos repetidos

Definición

Dado el conjunto S con n elementos, una permutación P de S es una secuencia

$$s_1, s_2, \ldots, s_n \quad s_i \in S$$

Para S con |S| = n, existen n! permutaciones diferentes

- Cada una es una forma de ordenar los elementos de S
- El arreglo A corresponde a una de esas permutaciones

Definiremos el número promedio de inversiones como el promedio aritmético del número de inversiones de cada una de las n! permutaciones

En lugar de contar inversiones para cada permutación, usaremos un truco

- Para una permutación P, consideremos su permutación inversa P^r
- Existen n!/2 pares de permutaciones acompañadas de su inversa

Ejemplo

Para n = 3, las 3! = 6 permutaciones de $S = \{4, 7, 8\}$ son

- $P_1 = 4,7,8 \text{ y } P_1^r = 8,7,4$
- $P_2 = 7, 4, 8$ y $P_2^r = 8, 4, 7$
- $P_3 = 7, 8, 4$ y $P_3^r = 4, 8, 7$

Tomando un par de elementos distintos x, y de S y un par de permutaciones P, P^r , los índices de x e y están en inversión en **alguna de las dos permutaciones**

Ejemplo

Para $S = \{4,7,8\}$, el par de elementos x = 4 e y = 8, y el siguiente par de permutaciones

$$P_2 = \begin{array}{|c|c|c|c|c|c|} \hline 7 & 4 & 8 \\ \hline & 0 & 1 & 2 \\ \hline \end{array}$$

$$P_2^r = \begin{array}{|c|c|c|c|c|} \hline 8 & 4 & 7 \\ \hline & 0 & 1 & 2 \\ \hline \end{array}$$

los índices de x, y en P_2 son (1,2) y en P_2^r , (1,0)

- En P_2 , como 1 < 2 y 4 < 8, (1,2) no es inversión
- En P_2^r , como 1 $\not \in$ 0 y 4 < 8, (0,1) es inversión

Un par de índices (i,j) es inversión en P o en P^r

Como cada inversión aparece en una de las dos permutaciones del par P, P^r ,

inv en
$$P + \#$$
 inv en $P^r = \frac{n(n-1)}{2}$

Luego, tomando los n!/2 pares posibles de permutaciones de la forma P_k, P_k^r , el promedio de inversiones es

$$\frac{\sum_{P} \left(\text{\# inv en } P \right)}{\text{\# permutaciones}} = \frac{\sum_{k=1}^{n!/2} \left(\text{\# inv en } P_k + \text{\# inv en } P_k^r \right)}{n!}$$

$$= \frac{\frac{n(n-1)}{2} \cdot n!/2}{n!}$$

$$= \frac{n(n-1)}{4}$$

Una permutación promedio tiene una cantidad de inversiones $\mathcal{O}(n^2)$

Con este resultado podemos concluir la complejidad de InsertionSort en el caso promedio

- La complejidad de InsertionSort es de la forma $\mathcal{O}(n+k)$
- En el caso promedio $k \in \mathcal{O}(n^2)$
- $lue{}$ Luego, en el caso promedio InsertionSort toma tiempo $\mathcal{O}(\mathit{n}^2)$

¡Ojo! Esto va más allá de InsertionSort

Caso promedio de algoritmos de ordenación

Teorema

Sea $\mathcal A$ un algoritmo de ordenación. Si $\mathcal A$ corrige una inversión por intercambio, entonces no puede ordenar más rápido que $\mathcal O(n^2)$ en el caso promedio.

Corolario

 ${\mathcal A}$ no puede ordenar más rápido que ${\mathcal O}(n^2)$ en el peor caso.

Complejidad de algoritmos de ordenación

Resumimos los resultados de complejidad por caso hasta el momento

| Algoritmo | Mejor caso | Caso promedio | Peor caso | Memoria adicional |
|----------------|------------------|--------------------|--------------------|----------------------|
| Selection Sort | ? | ? | ? | $\mathcal{O}(1)$ |
| Insertion Sort | $\mathcal{O}(n)$ | $\mathcal{O}(n^2)$ | $\mathcal{O}(n^2)$ | $\mathcal{O}(1)$ |
| Quick Sort | ? | ? | ? | ? |
| Merge Sort | ? | ? | ? | ? |
| Heap Sort | ? | ? | ? | ? |

Ejercicio (propuesto)

Aplicando las estrategias que vimos hoy

- Escriba el pseudocódigo de la versión in place de SelectionSort
- Especifique complejidad del mejor, peor y caso promedio de SelectionSort() de acuerdo a su propuesta

Sumario

Introducción

Insertion Sort

Inversiones

Cierre

Objetivos de la clase

- ☐ Distinguir diferencias de InsertionSort y SelectionSort
- Demostrar correctitud de InsertionSort
- Comprender el efecto de la inserción general en las EDD básicas
- Comprender concepto de inversión y su rol en la ordenación
- Comprender casos (mejor, peor y promedio) en análisis en complejidad
- ☐ Determinar complejidad por caso para InsertionSort